RELATÓRIO FINAL DE BASE DE DADOS E DATA WAREHOUSE

Unidade Curricular: Base de Dados e Data Warehouse

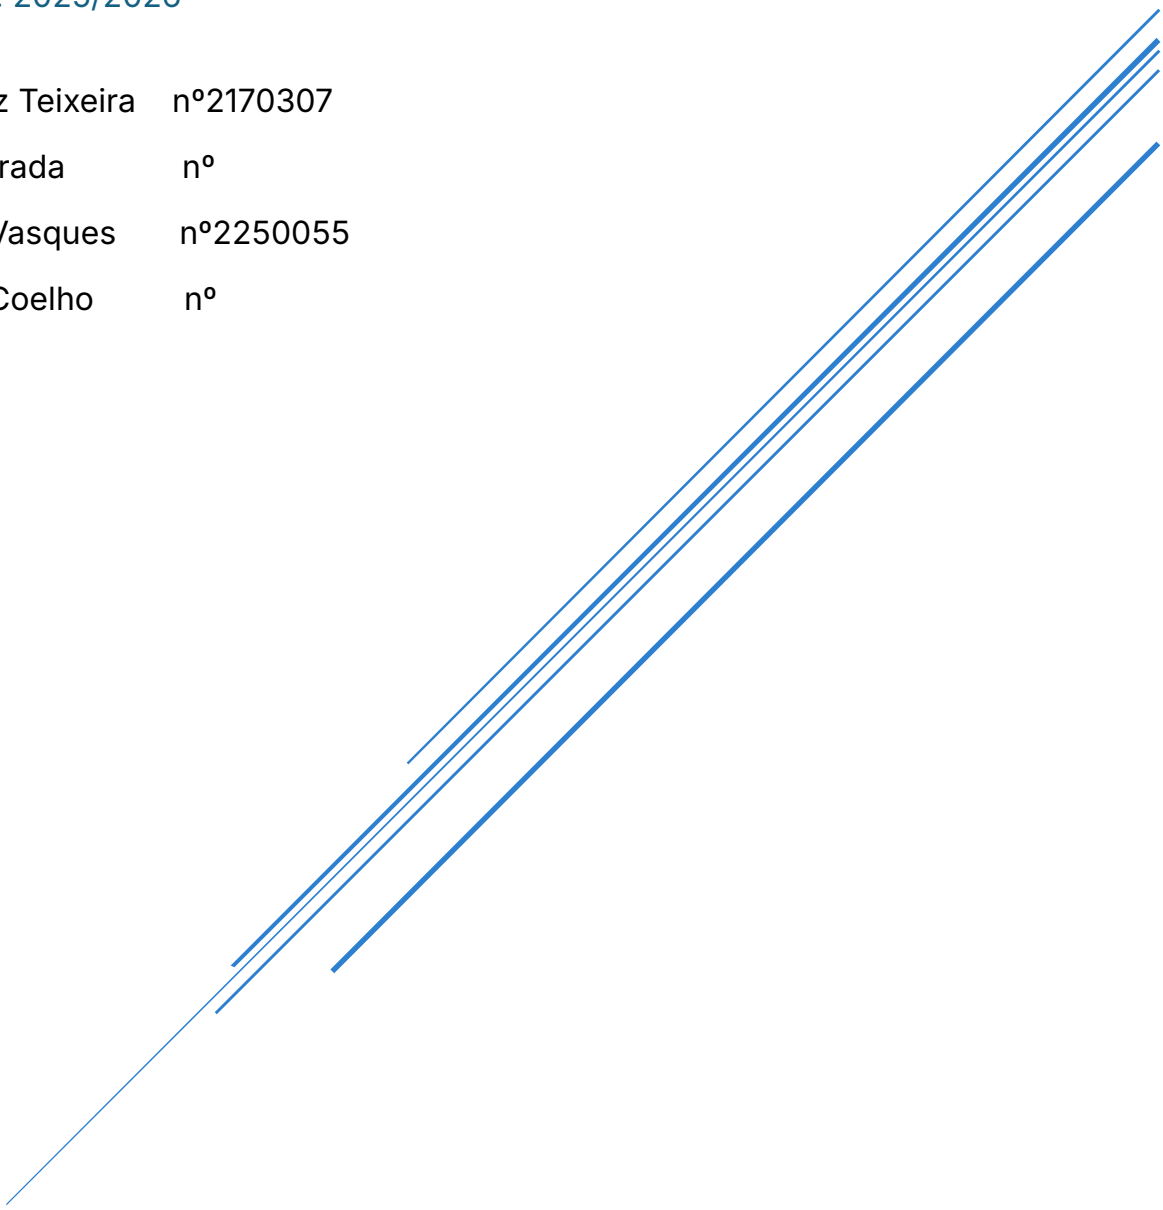
Ano letivo: 2025/2026

Beatriz Teixeira nº2170307

Rui Parada nº

João Vasques nº2250055

João Coelho nº



Instituto Superior de Contabilidade e Administração do Porto

Mestrado em Business Intelligence and Analytics

Índice

1. Introdução....3
1.1. Explicação do Dataset original....3
1.1.1. Transaction....3
1.1.2 Faixa Etária....4
1.1.3. Género....4
1.1.4. Product Category....4
2. Normalização dos Dados....4
2.1. Primeira Forma Normal (1FN)....5
2.2. Segunda Forma Normal (2FN)....5
2.3. Terceira Forma Normal (3FN)....6
4. Implementação do Modelo E-R em SQL....8
4.1. Criação da Base de Dados....8
4.2. Implementação das Tabelas....8
4.2.1. Tabela Gender....8
4.2.2. Tabela Faixa_Etaria....8
4.2.3. Tabela Product_Category....9
4.2.4. Tabela Customer....9
4.2.5. Tabela Transaction....9
4.2.6. Tabela Associativa Transaction_Product_Category....10
4.3. Diagrama do modelo E-R....11
5. Processo de ETL (Extract, Transform, Load)....11
6. Modelo de Dados (Data Warehouse)....12
6.1. Modelo de Dados (visão geral)....12
6.2. Tabela de Factos....13
6.3. Tabelas de Dimensão....14
6.4. Relações e Cardinalidades....15
6.5. Criação da Dimensão Temporal....16
7. Questões de Negócio que o DW pretende responder....16
8. Medidas e Cálculos em DAX....17
9. Métricas e indicadores de desempenho....18
9.1. Métricas Fundamentais (Core KPIs)....18
9.2. Inteligência Temporal....19

9.3. Análise de Comportamento do Cliente.....21
9.4. Análise Estatística Avançada.....22
9.5. Segmentação e Concentração (Pareto).....24
10. Dashboard e visualizações.....25
10.1. Escolha dos tipos de visualização.....25
10.2. Interpertação dos resultados.....26
11. Conclusão.....27
12. Referências.....27

1. Introdução

No âmbito da unidade curricular de Base de Dados e Data Warehouse, foi proposto a conceção e o desenvolvimento de uma Data Warehouse (Data Mart) e posterior análise através da construção de visualizações e *dashboards* com recurso ao PowerBI.

Relativamente ao conjunto de dados propostos disponibilizados via Moodle pela docente, foi selecionado pelo grupo o *Dataset* denominado: *Retail Sales Data Project*. Trata-se de um conjunto de dados de natureza transacional, representativo de um processo de vendas ao cliente final, contendo registos individuais de compras realizadas, bem como informação complementar sobre clientes e a categoria dos produtos transacionados. Os dados encontram-se em folhas de Excel apresentados em formato tabular, o que permitiu a posterior normalização e integração num modelo relacional.

Através da interpretação do *Dataset*, percebemos que o processo de negócio subjacente corresponde ao ciclo de venda de produtos a clientes, desde o momento em que a transação é registada até à identificação das características do cliente e das categorias de produtos adquiridos.

1.1. Explicação do Dataset original

A tabela de Excel com a *Original Data* é composta por 9 colunas:

- Transaction ID
- Date
- Customer ID
- Gender
- Age
- Product Category
- Quantity
- Price per Unit
- Total Amount

No entanto, são disponibilizadas 4 folhas de Excel adicionais que contém informação das diferentes componentes que serão alvo de análise.

1.1.1. Transaction

Nas transações são apresentadas as informações de cada transação que foi feita na loja, cada transação é identificada pelo *Transaction ID* (corresponde a um atributo inteiro com incremento automático). São fornecidos os dados respetivos à data da transferência, do cliente a que corresponde (através do Customer ID), o ID do género, ID da faixa etária, ID da categoria de produto, quantidade adquirida do produto, preço unitário (*Price per Unit*) e montante total da transação (*Total Amount*).

1.1.2 Faixa Etária

A idade do cliente é tratada através de grupos etários: menores de 25 anos, entre os 25 e 34, 44 a 54 e, por fim, 55-64 anos de idade, identificados por um ID de 1 a 5, respetivamente

1.1.3. Género

A tabela género apresenta duas colunas: *Id Gender* e *Gender*, sendo que existem dois géneros (*Male* e *Female*) identificados por Id (1 e 2, respetivamente).

1.1.4. Product Category

Neste caso prático estão presentes 3 tipos de produtos no *dataset*: *Beauty, Clothing* e *Electronics*. Semelhante ao resto dos dados, cada categoria é identificada por um ID de 1 a 3, respetivamente.

2. Normalização dos Dados

Antes de começar a elaborar o modelo E-R foi necessário proceder à normalização dos dados.

Transaction

Transaction ID

Date

Customer ID

ID Gender

Gender

ID Faixa Etaria

Faixa Etaria

Product Category*

ID Product Category

Product Category

Quantity

Price per Unit

Total Amount

Figura 1- Dados Não Normalizados

2.1. Primeira Forma Normal (1FN)

O objetivo da primeira forma normal é de eliminar atributos repetidos, ou seja, todos os atributos têm de ser valores atómicos.

Neste caso prático os dados já se encontram na primeira forma normal, não existia necessidade de criar a tabela associativa de *Transaction* e *Product_Category* dado que uma transação só contém um tipo de produto. No entanto, para garantir flexibilidade futura do modelo, decidimos implementar esse cenário:

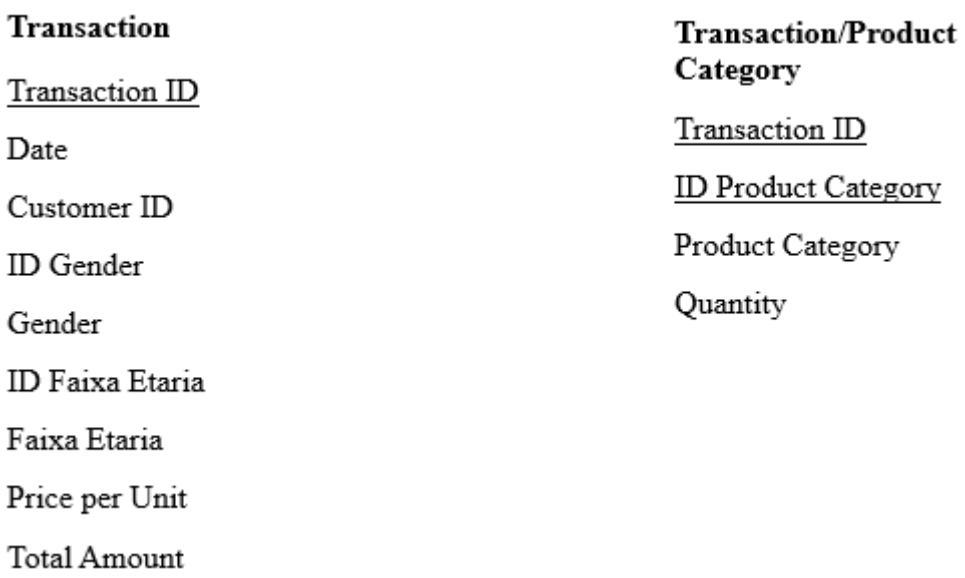
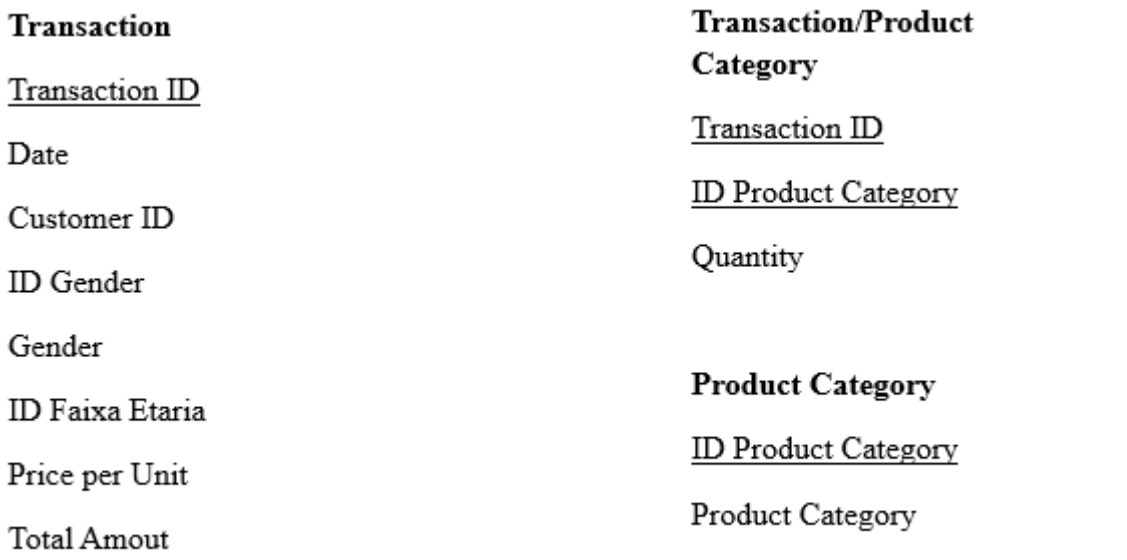


Figura 2- Primeira Forma Normal

Da forma que os dados são apresentados, não se verifica nenhum atributo ou grupo repetido, cada linha é identificada por Transaction ID, permitindo avançar diretamente para a segunda forma normal.

2.2. Segunda Forma Normal (2FN)

Na segunda forma normal o objetivo passa por verificar dependências funcionais da totalidade da chave. É necessário que os dados estejam na primeira forma normal e que cada elemento não chave dependa funcionalmente da totalidade da chave e não de parte da



chave.

Figura 3- Segunda Forma Normal

Tendo em conta que os dados já estavam na primeira forma normal, procedemos à análise das dependências funcionais necessárias para alcançar a 2FN. Nesta fase é exigido que nenhum atributo não-chave dependa apenas de uma parte da chave primária, procurando assim eliminar dependências parciais.

A tabela *Transaction* já cumpria este requisito, uma vez que possui uma chave primária simples (*Transaction_ID*). Como não existe chave composta, não podem existir dependências parciais, pelo que a tabela permanece inalterada nesta fase.

A tabela *Transaction/Product Category*, contudo, apresenta uma chave primária composta pelos atributos (*Transaction ID, ID Product Category*). Durante a análise das dependências funcionais verificou-se que o atributo Product Category não dependia da chave composta, mas apenas de uma das suas partes, do *ID Product Category*. Esta situação representa uma violação da 2FN, pois representa uma dependência parcial.

Para resolver este problema o atributo *Product Category* foi removido da tabela associativa e colocado numa nova entidade, *Product Category*, onde passa a depender exclusivamente da sua chave primária (ID Product Category).

2.3. Terceira Forma Normal (3FN)

Por fim, na 3FN é necessário verificar as dependências funcionais entre atributos não chave. Os dados têm de se encontrar na segunda forma normal e cada atributo deve

depender funcionalmente apenas da chave primária da relação e não de atributos não chave.

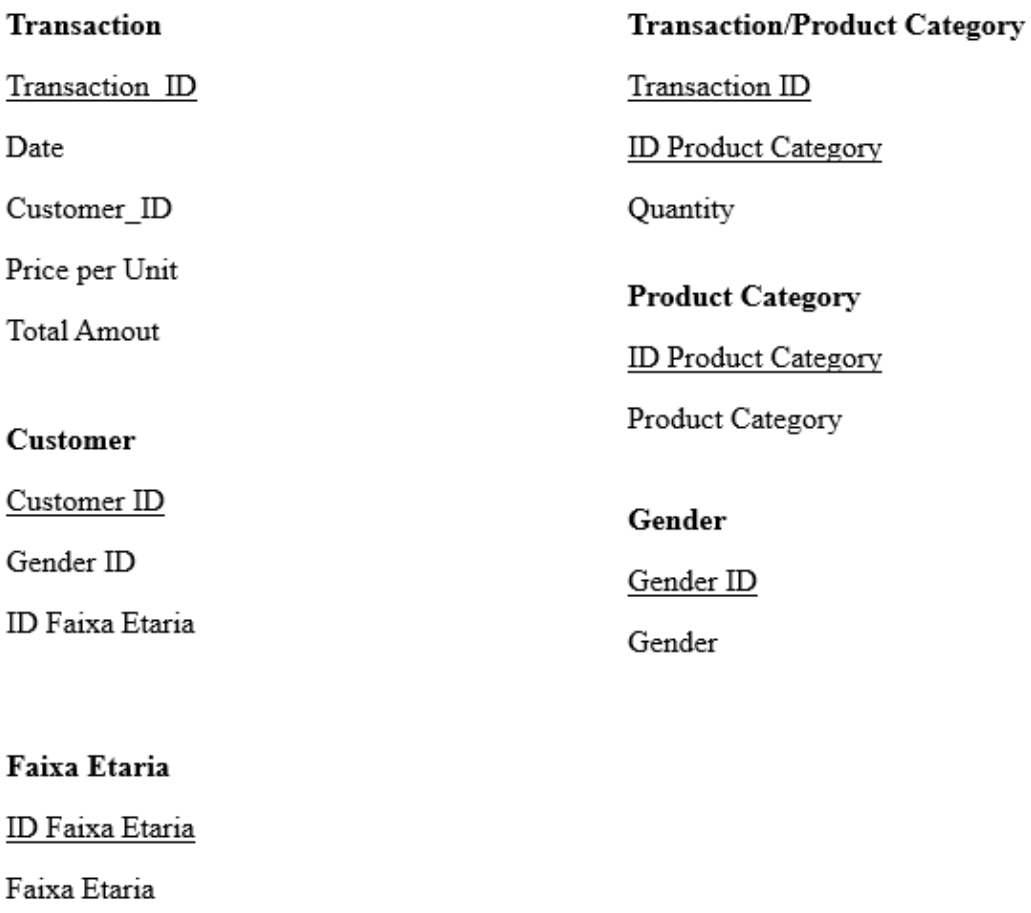


Figura 4- Terceira Forma Normal

Analisada a segunda forma normal, verificamos que na tabela *Transaction/Product Category* e *Product Category* já se encontram na 3FN após a normalização anterior, uma vez que todos os seus atributos dependiam diretamente das respetivas chaves primárias. Contudo, existe dependência transitiva na tabela *Transaction*. Atributos como *Gender*, *Faixa Etaria* e os respetivos *ID* não dependiam diretamente da chave primária *Transaction_ID*. Para eliminar essa dependência foram criadas as tabelas: *Customer*, *Gender* e *Faixa Etaria*. A tabela *Transaction* passa a incluir apenas o *Customer_ID* assegurando que todos os restantes atributos dependem diretamente da chave primária da tabela.

Com estas alterações, o modelo relacional passou a apresentar uma estrutura totalmente normalizada, evitando redundâncias e reforçando a integridade lógica.

4. Implementação do Modelo E-R em SQL

4.1. Criação da Base de Dados

Para a implementação em SQL recorremos ao uso do software MySQL Workbench 8.0 para implementar o modelo E-R.

Figura 5- Criação da Base de Dados e respetiva seleção

```
1 •   CREATE DATABASE Retail_Sales_Data_Project;
2
3 •   USE Retail_Sales_Data_Project;
```

Primeiramente criamos a base de dados através do comando: "*CREATE DATABASE*", atribuindo o nome de *Retail_Sales_Data_Project*. Antes de criar as tabelas, com recurso do comando "*USE*" selecionamos a base de dados criada.

4.2. Implementação das Tabelas

Tendo em conta o ponto anterior, dentro da base de dados utilizamos o comando "*CREATE TABLE*" para proceder à criação das tabelas apresentadas no capítulo anterior na 3FN.

4.2.1. Tabela Gender

A tabela *Gender* é constituída por dois atributos: a *chave primária* (*ID_Gender*), definida como *INT* por ser um identificador numérico e o atributo *Gender*, definido como *VARCHAR*, permitindo armazenar o texto correspondente aos dois géneros do *Dataset* (*male* e *female*).

```
19 • CREATE TABLE Gender (
20       ID_Gender        INT PRIMARY KEY,
21       Gender           VARCHAR(20) NOT NULL
22   );
```

Figura 6- Implementação da Tabela Gender

4.2.2. Tabela Faixa_Etaria

A tabela *Faixa_Etaria* é constituída por dois atributos: a *chave primária* (*ID_Faixa_Etaria*), definida como *INT* por ser um identificador numérico simples para cada grupo etário e o atributo *Faixa_Etaria*, definido como *VARCHAR*, dado que os grupos etários estão definidos em intervalos e não em valores inteiros únicos.

```
25 • CREATE TABLE Faixa_Etaria (
26       ID_Faixa_Etaria  INT PRIMARY KEY,
27       Faixa_Etaria     VARCHAR(50) NOT NULL
28   );
```

Figura 7- Implementação da Tabela Faixa_Etaria

4.2.3. Tabela Product_Category

A tabela *Product_Category* é constituída por dois atributos: a *chave primária* (*ID_Product_Category*), definida como *INT* por ser um identificador numérico e o atributo *Product_Category*, definido como *VARCHAR*, permitindo armazenar texto para representar as diferentes categorias de produtos.

```
31  CREATE TABLE Product_Category (
32      ID_Product_Category  INT PRIMARY KEY,
33      Product_Category     VARCHAR(100) NOT NULL
34  );
```

Figura 8- Implementação da Tabela Product_Category

4.2.4. Tabela Customer

A tabela *Customer* é constituída por três atributo: a *chave primária* (*Customer_ID*), definida como *INT* por ser um identificador numérico e os atributos *ID_Gender* e *ID_Faixa_Etaria*, também definidos como *INT* por representarem chaves estrangeiras que estabelecem ligações diretas às tabelas *Gender* e *Faixa_Etaria*. A utilização de *CONSTRAINT* e *REFERENCES* permite declarar explicitamente estas relações, assegurando que os valores inseridos correspondem a registos existentes nas tabelas relacionadas e garantindo a integridade referencial do modelo.

```
37  CREATE TABLE Customer (
38      Customer_ID       INT PRIMARY KEY,
39      ID_Gender         INT NOT NULL,
40      ID_Faixa_Etaria   INT NOT NULL,
41      CONSTRAINT fk_customer_gender
42          FOREIGN KEY (ID_Gender)
43          REFERENCES Gender(ID_Gender),
44      CONSTRAINT fk_customer_faixa_etaria
45          FOREIGN KEY (ID_Faixa_Etaria)
46          REFERENCES Faixa_Etaria(ID_Faixa_Etaria)
47  );
```

Figura 9- Implementação da Tabela Customer

4.2.5. Tabela Transaction

A tabela *Transaction* é constituída por cinco atributos: a chave primária (*Transaction_ID*), definida como *INT*; o atributo *Date*, definido como *DATE* para armazenar a data da transação; o atributo *Customer_ID*, definido como *INT* por representar a chave estrangeira que identifica o cliente associado e os atributos *Price_per_Unit* e *Total_Amount*, ambos definidos como *DECIMAL(10,2)* para permitir o registo de valores monetários. Mas uma vez foram utilizados os comandos *CONSTRAINT* e *REFERENCES* para estabelecer a relação entre *Customer_ID* e a tabela *Customer*, garantindo que cada

transação está associada a um cliente existente e assegurando a integridade referencial do modelo.

```
50  CREATE TABLE Transaction (
51      Transaction_ID    INT PRIMARY KEY,
52      Date              DATE NOT NULL,
53      Customer_ID       INT NOT NULL,
54      Price_per_Unit    DECIMAL(10,2) NOT NULL,
55      Total_Amount      DECIMAL(10,2) NOT NULL,
56      CONSTRAINT fk_transaction_customer
57          FOREIGN KEY (Customer_ID)
58          REFERENCES Customer(Customer_ID)
59  );
```

Figura 10- Implementação da Tabela Transaction

4.2.6. Tabela Associativa Transaction_Product_Category

A tabela *Transaction_Product_Category* funciona como uma tabela associativa entre *Transaction* e *Product_Category*. É constituída por três atributos: *Transaction_ID* e *ID_Product_Category*, ambos definidos como *INT* por representarem chaves estrangeiras que estabelecem a ligação entre as duas tabelas principais; e o atributo *Quantity*, definido como *INT* para registar a quantidade de produtos envolvidos na transação. À semelhança das tabelas anteriores, o comando *CONSTRAINT* e *REFERENCES* permite declarar explicitamente estas relações, assegurando que cada registo corresponde a uma combinação válida entre uma transação existente e uma categoria de produto existente, garantindo assim a integridade referencial do modelo.

```
62  CREATE TABLE Transaction_Product_Category (
63      Transaction_ID       INT NOT NULL,
64      ID_Product_Category  INT NOT NULL,
65      Quantity             INT NOT NULL,
66      CONSTRAINT pk_transaction_product_category
67          PRIMARY KEY (Transaction_ID, ID_Product_Category),
68      CONSTRAINT fk_tpc_transaction
69          FOREIGN KEY (Transaction_ID)
70          REFERENCES Transaction(Transaction_ID),
71      CONSTRAINT fk_tpc_product_category
72          FOREIGN KEY (ID_Product_Category)
73          REFERENCES Product_Category(ID_Product_Category)
74  );
```

Figura 11- Implementação da Tabela Associativa Transaction_Product_Category

4.3. Diagrama do modelo E-R

Implementadas as tabelas, e recorrendo às funcionalidades disponibilizadas pelo software utilizado, aplicámos a função *Reverse Engineer*, que, através da leitura direta da estrutura existente na base de dados, gera automaticamente o diagrama E-R correspondente. Desta forma obtemos a representação gráfica de todas as tabelas, os seus atributos e as relações definidas entre elas, assegurando que o modelo visual reflete com precisão a implementação real do esquema relacional.

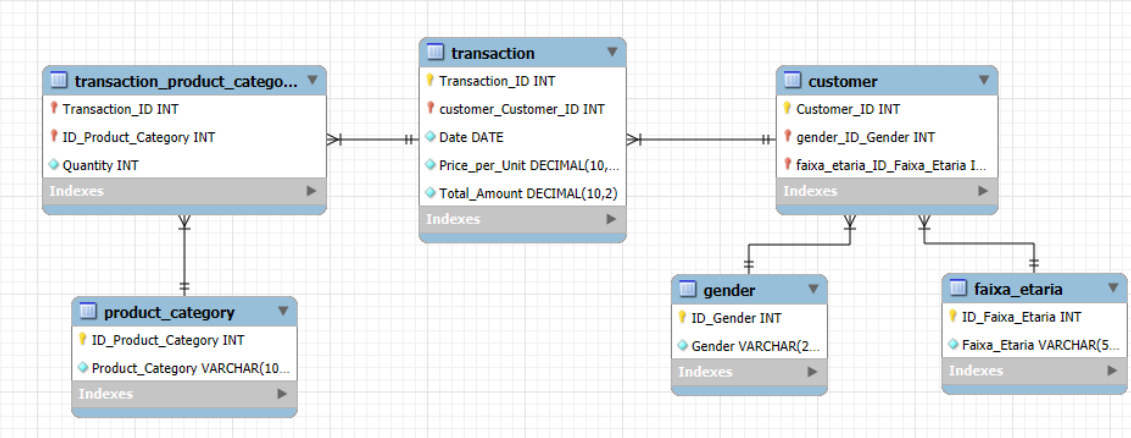


Figura 12 – Diagrama do Modelo E-R

No diagrama desenvolvido, as cardinalidades estabelecem as relações lógicas entre as entidades do sistema. Entre as tabelas *Customer* e *Transaction* estabelece-se uma relação *um-para-muitos*, uma vez que um único cliente pode realizar várias transações, enquanto cada transação está sempre associada a um único cliente.

A tabela *Transaction_Product_Category* funciona como tabela associativa e, por isso, estabelece duas relações *muitos-para-um*: cada registo desta tabela corresponde a uma combinação específica entre uma transação e uma categoria de produto, mas na adaptação realizada, cada transação pode envolver várias categorias e cada categoria pode surgir em múltiplas transações.

As tabelas *Gender* e *Faixa_Etaria* relacionam-se com a *Customer* também através de relações *um-para-muitos*. Cada género e cada faixa etária podem estar associados a vários clientes, mas cada cliente pertence apenas a um género e a uma faixa etária.

5. Processo de ETL (Extract, Transform, Load)

O processo de ETL foi realizado recorrendo ao **Power Query**, módulo integrado no Power BI responsável pela extração, transformação e carregamento dos dados. Os dados utilizados neste projeto foram inicialmente disponibilizados em ficheiros Excel, que serviram como fonte de dados para o processo de análise. A importação dos dados para o Power BI foi realizada através de SQL recorrendo ao Power Query para efetuar operações de limpeza, transformação e normalização dos dados.

Durante este processo, foram garantidas a coerência dos tipos de dados, a consistência das chaves utilizadas nas relações entre tabelas e a adequação dos dados ao modelo dimensional definido. Após a fase de preparação, os dados foram carregados para o modelo, permitindo a construção da tabela de factos e das respetivas dimensões.

As principais operações realizadas nesta fase incluíram:

- Remoção de valores duplicados e inconsistentes, de forma a garantir integridade dos dados;
- Alteração e normalização dos tipos de dados, assegurando compatibilidade com o modelo relacional;
- Renomeação de colunas, promovendo clareza semântica e uniformização da nomenclatura;
- Criação de colunas de índice sempre que necessário para suporte à análise;
- Filtragem de dados irrelevantes para o contexto analítico do projeto;
- Definição e correção de tipos de dados (Texto, Número Inteiro, etc)

Estas transformações permitiram preparar os dados para uma modelação eficiente e adequada às necessidades analíticas do projeto.

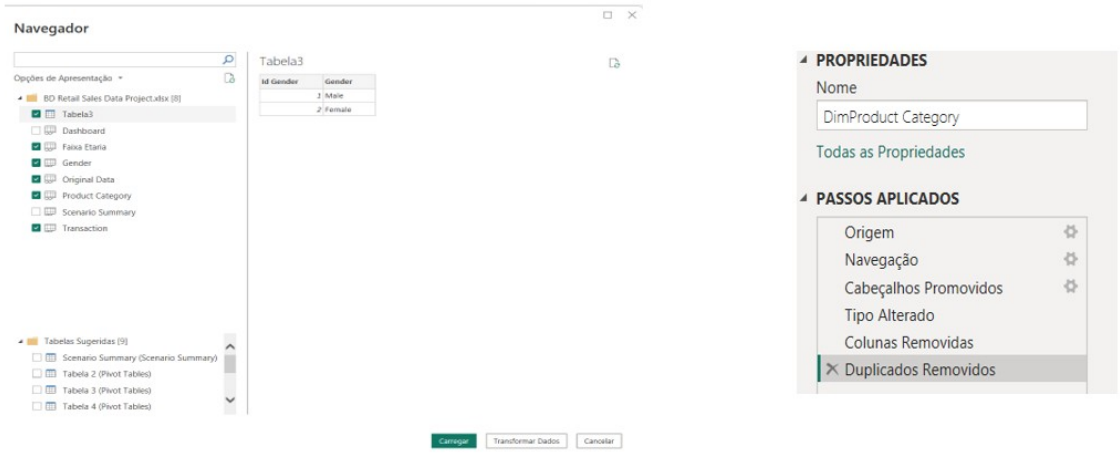


Figura 13- Vista geral do Power Query Editor com as tabelas importadas

Conforme ilustrado na Figura 13, o Power Query desempenhou um papel fundamental na fase de preparação dos dados, assegurando que estes se encontravam devidamente estruturados antes de serem carregados para o modelo analítico.

6. Modelo de Dados (Data Warehouse)

6.1. Modelo de Dados (visão geral)

Após a fase de ETL, procedeu-se à construção do modelo de dados no Power BI. O modelo foi desenvolvido seguindo uma abordagem típica de Data Warehouse, baseada num esquema em estrela, de forma a otimizar o desempenho das consultas e simplificar a análise dos dados.

O modelo é constituído por:

- Uma tabela de factos (FactSales), responsável por armazenar os dados quantitativos a analisar;
- Várias tabelas de dimensão, que fornecem contexto descritivo aos dados, nomeadamente: *DimCustomer*, *DimData*, *DimFaixaEtária*, *DimGender* e *DimProductCategory*.
- As relações entre as tabelas foram definidas com cardinalidade um-para-muitos (1: *), garantindo a integridade referencial e permitindo a correta propagação de filtros durante a análise.

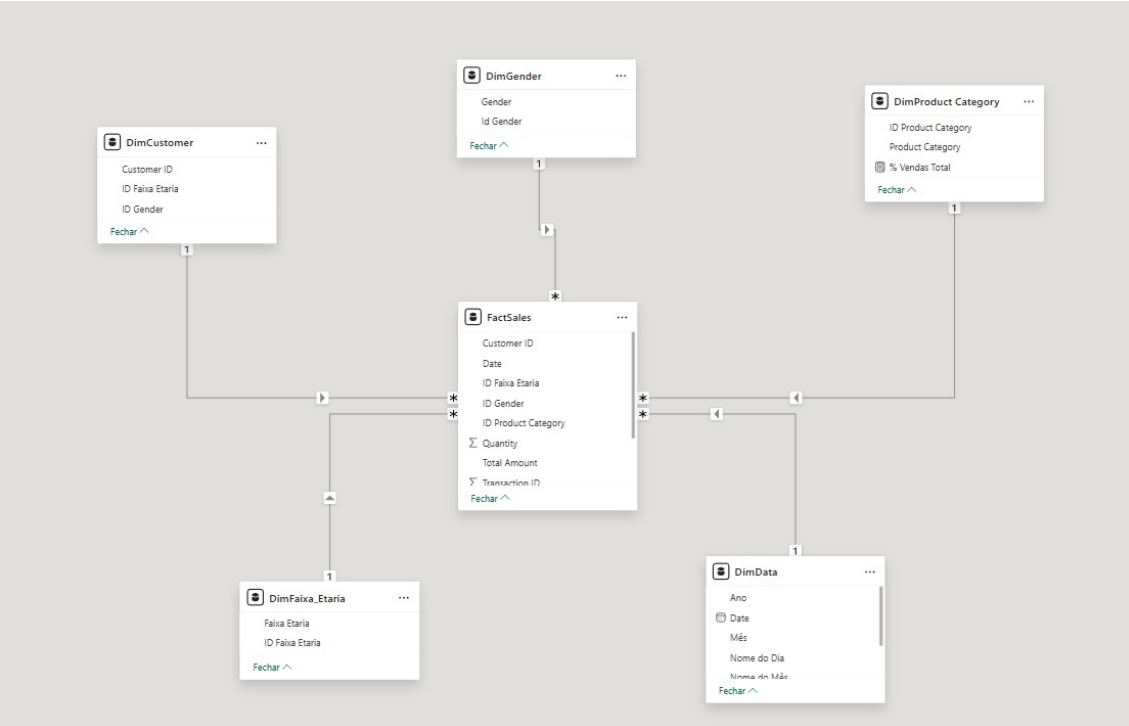


Figura 14- Modelo de dados em Estrela

A Figura 2 apresenta o modelo de dados desenvolvido, evidenciando a separação entre tabelas de factos e dimensões, bem como as relações estabelecidas entre estas. Esta estrutura contribui para uma maior eficiência na execução das medidas analíticas e facilita a interpretação dos resultados.

6.2. Tabela de Factos

A tabela de factos, denominada **FactSales**, constitui o núcleo do modelo analítico, sendo responsável pelo armazenamento das **medidas quantitativas** associadas ao negócio (vendas). Cada registo nesta tabela representa uma transação ou linha de venda.

A **FactSales** é composta pelas seguintes colunas principais:

- CustomerID – Chave estrangeira que referencia a dimensão *DimCustomer*, permitindo associar cada venda a um cliente específico;

- DateID – Chave estrangeira que referencia a dimensão temporal (*DimData*), possibilitando a análise cronológica das vendas;
- ProductCategoryID – Chave estrangeira associada à dimensão *DimProductCategory*, permitindo a análise por categoria de produto;
- GenderID – Chave estrangeira associada à dimensão *DimGender*, utilizada para segmentação demográfica;
- FaixaEtariaID – Chave estrangeira associada à dimensão *DimFaixaEtária*, permitindo análises por grupos etários;
- Quantity – Medida quantitativa que representa o número de unidades vendidas em cada transação;
- TotalAmount – Medida monetária que representa o valor total da venda, calculado com base no preço unitário e na quantidade vendida.

6.3. Tabelas de Dimensão

As tabelas de dimensão fornecem contexto descritivo às medidas presentes na tabela de factos, permitindo a realização de análises detalhadas e segmentadas sob diferentes perspetivas.

- **DimCustomer:**

A dimensão DimCustomer armazena informação relacionada com os clientes e inclui as seguintes colunas:

Customer ID – Chave primária da dimensão;

ID Faixa Etária – Identificador que permite associar o cliente a um grupo etário;

ID Gender – Identificador associado ao género do cliente.

Esta dimensão é utilizada para análises de comportamento do cliente e segmentações demográficas.

- **DimGender:**

A dimensão DimGender permite a classificação dos clientes por género e contém:

ID Gender – Chave primária da dimensão;

Gender – Descrição textual do género.

- **DimFaixa_Etaria:**

A dimensão DimFaixa_Etaria permite agrupar os clientes por intervalos etários, sendo composta por:

ID Faixa Etária – Chave primária da dimensão;

Faixa Etária – Descrição do intervalo etário correspondente.

- **DimProduct_Category:**

A dimensão DimProduct_Category descreve a categorização dos produtos vendidos e inclui:

ID Product Category – Chave primária da dimensão;

Product Category – Designação da categoria do produto.

- **DimData:**

A dimensão temporal DimData é responsável por suportar análises baseadas no tempo e contém os seguintes atributos:

Date – Chave primária da dimensão temporal;

Ano – Ano da transação;

Mês – Mês da transação;

Nome e Número do Dia, Mês e Trimestre.

6.4. Relações e Cardinalidades

As relações entre a tabela FactSales e as diferentes tabelas de dimensão foram definidas com cardinalidade um-para-muitos (1:*), onde cada registo de uma dimensão pode estar associado a múltiplas ocorrências na tabela de factos. A direção de filtragem foi configurada de modo a permitir a correta propagação dos filtros das dimensões para a tabela de factos.

Esta configuração garante a integridade referencial do modelo, facilita a criação de medidas em DAX e assegura a coerência dos resultados analíticos apresentados nos *dashboards*.

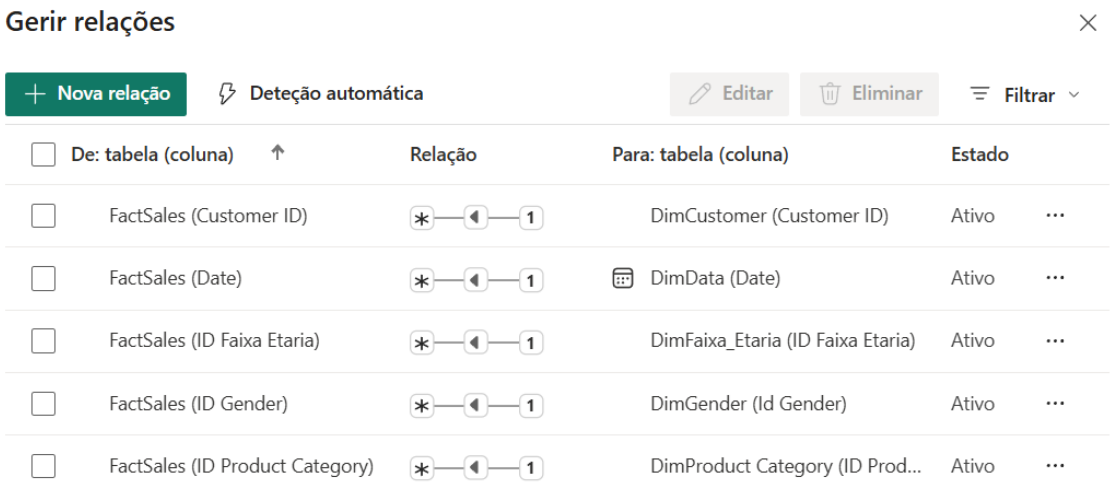


Figura 15 - Relações e cardinalidades entre as tabelas

6.5. Criação da Dimensão Temporal

A dimensão temporal foi criada de forma dedicada, através da construção de um calendário próprio, com o objetivo de garantir consistência temporal, flexibilidade analítica e suporte adequado às funcionalidades de *time intelligence* implementadas no Power BI.

O calendário desenvolvido inclui uma linha por cada data do intervalo temporal abrangido pelos dados, permitindo representar corretamente a evolução cronológica das vendas. A partir da coluna base Date, foram derivados diversos atributos temporais, nomeadamente Ano, Mês, Nome do Mês/Dia, Trimestre e Número do Dia possibilitando análises hierárquicas e agregações em diferentes níveis de granularidade.

A utilização de uma dimensão temporal independente permite evitar dependências diretas de datas na tabela de factos (*FactSales*), assegurando que todas as análises temporais são realizadas de forma uniforme e controlada. Esta abordagem é particularmente relevante para a implementação de métricas de comparação temporal, como crescimento *Month-over-Month* (MoM) e *Year-over-Year* (YoY), que requerem uma sequência temporal contínua e sem lacunas.

Date	Ano	Mês	Trimestre	Nome do Mês	Nome do Dia	Numero Dia
24 de novembro de 2023	2023	11	4	novembro	sexta-feira	5
13 de dezembro de 2023	2023	12	4	dezembro	quarta-feira	3
7 de outubro de 2023	2023	10	4	outubro	sábado	6
30 de outubro de 2023	2023	10	4	outubro	segunda-feira	1
5 de novembro de 2023	2023	11	4	novembro	domingo	7
15 de outubro de 2023	2023	10	4	outubro	domingo	7
29 de novembro de 2023	2023	11	4	novembro	quarta-feira	3
26 de dezembro de 2023	2023	12	4	dezembro	terça-feira	2
29 de outubro de 2023	2023	10	4	outubro	domingo	7
24 de dezembro de 2023	2023	12	4	dezembro	domingo	7
6 de novembro de 2023	2023	11	4	novembro	segunda-feira	1
2 de outubro de 2023	2023	10	4	outubro	segunda-feira	1
10 de outubro de 2023	2023	10	4	outubro	terça-feira	2
18 de novembro de 2023	2023	11	4	novembro	sábado	6
13 de novembro de 2023	2023	11	4	novembro	segunda-feira	1
23 de outubro de 2023	2023	10	4	outubro	segunda-feira	1
27 de dezembro de 2023	2023	12	4	dezembro	quarta-feira	3
5 de dezembro de 2023	2023	12	4	dezembro	terça-feira	2
22 de novembro de 2023	2023	11	4	novembro	quarta-feira	3
10 de dezembro de 2023	2023	12	4	dezembro	domingo	7
16 de dezembro de 2023	2023	12	4	dezembro	sábado	6
28 de novembro de 2023	2023	11	4	novembro	terça-feira	2
8 de novembro de 2023	2023	11	4	novembro	quarta-feira	3
1 de outubro de 2023	2023	10	4	outubro	domingo	7
19 de dezembro de 2023	2023	12	4	dezembro	terça-feira	2
13 de outubro de 2023	2023	10	4	outubro	sexta-feira	5
17 de dezembro de 2023	2023	12	4	dezembro	domingo	7
18 de outubro de 2023	2023	10	4	outubro	quarta-feira	3

Figura 16 - Estrutura da Dimensão Temporal

7. Questões de Negócio que o DW pretende responder

Com base no modelo dimensional desenvolvido e nos dados disponibilizados, foram definidas as seguintes questões de negócio, cujo objetivo é apoiar a análise do desempenho de vendas, do comportamento dos clientes e da procura por produtos, servindo de base à construção das métricas, dashboards e visualizações no Power BI.

Vendas

1. Em que meses as vendas são mais fortes/fracas?

2. Qual é o valor médio por transação?

3. Em que dias da semana as vendas são mais altas?

Clientes

1. Qual é a idade média dos clientes que mais compram?

2. Há diferença entre clientes mais novos e mais velhos em termos de gasto?

Produtos

1. Que categoria tem maior consistência de vendas ao longo do tempo?

Segmentos

1. Qual a categoria é preferida por cada género?

2. Que faixa etária compra mais cada categoria?

8. Medidas e Cálculos em DAX

Após a definição e validação do modelo de dados dimensional, procedeu-se à implementação da lógica de negócio utilizando a linguagem DAX (Data Analysis Expressions). Esta etapa foi fundamental para transformar os dados brutos armazenados no Data Warehouse em informação acionável, permitindo o cálculo de indicadores-chave de desempenho (KPIs) dinâmicos e adaptáveis ao contexto de análise.

As medidas desenvolvidas não se limitaram a agregações simples, abrangendo também cálculos estatísticos avançados para responder a questões complexas do negócio. As métricas foram categorizadas nas seguintes áreas:

- **Métricas Fundamentais:** Totais, contagens distintas e médias aritméticas;
- **Inteligência Temporal:** Comparativos homólogos (YoY) e evolutivos (MoM) para análise de tendências;
- **Comportamento do Cliente:** Taxas de retenção, repetição de compra e diversidade de consumo;
- **Análise Estatística Avançada:** Correlações, elasticidade de preço, volatilidade e deteção de anomalias.

Todas as medidas tiram partido do contexto de filtro do modelo relacional, garantindo a integridade dos resultados independentemente das segmentações aplicadas pelo utilizador final. Abaixo, apresentam-se as principais medidas implementadas (para verificar as restantes consultar no Power Bi).

9. Métricas e indicadores de desempenho

9.1. Métricas Fundamentais (Core KPIs)

Estas medidas constituem a base quantitativa do relatório, sobre as quais são construídos os indicadores mais complexos.

1. Total de vendas:

```
Total Vendas

Total Vendas := SUM ( FactSales[Total Amount] )
```

Figura 17- Total de Vendas

Soma absoluta do valor monetário de todas as transações registadas. Representa a faturação bruta da organização.

O cálculo é efetuado com base na coluna TotalAmount da tabela FactSales, sendo agregado de acordo com o contexto de filtro aplicado pelas dimensões *DimData*, *DimCustomer*, *DimGender*, *DimFaixa_Etaria* e *DimProduct_Category*.

2. Quantidade total:

```
Quantidade Total:

Quantidade Total := SUM ( FactSales[Quantity] )
```

Figura 18 - Quantidade Total

Volume total de unidades de produtos vendidas no período selecionado.

O cálculo utiliza a coluna Quantity da tabela FactSales, permitindo analisar volumes de venda independentemente do valor monetário associado.

3. Número de Transações:

```
Nr Transações:

Nr Transações := DISTINCTCOUNT ( FactSales[Transaction ID] )
```

Contagem distinta dos identificadores de transação, permitindo aferir o tráfego de vendas independentemente do número de itens por cesto.

O cálculo baseia-se na coluna Transaction ID da tabela FactSales, permitindo aferir o número de atos de compra independentemente do número de itens adquiridos por transação.

4. Ticket Médio:

```
Ticket Médio:

Ticket Médio := DIVIDE ( [Total Vendas], [Nr Transações] )
```

Figura 20- Ticket Médio

Valor médio gasto por cada ato de compra. É um indicador primário de eficiência comercial e da capacidade de aumento do valor por transação.

É calculada através da razão entre:

- a soma da coluna TotalAmount (*FactSales*),
- e a contagem distinta da coluna Transaction ID (*FactSales*).

Este indicador depende diretamente da granularidade da tabela de factos.

9.2. Inteligência Temporal

Métricas focadas na evolução do desempenho ao longo do tempo, essenciais para identificar sazonalidade e tendências de crescimento.

1. Crescimento MoM (%):

```
Crescimento MoM % (Mês anterior):

Crescimento MoM % :=
DIVIDE (
    [Total Vendas] - [Vendas Mês Anterior],
    [Vendas Mês Anterior]
)
```

Figura 21- Crescimento MoM(%)

Variação percentual das vendas face ao mês imediatamente anterior (*Month-over-Month*). Valores positivos indicam crescimento a curto prazo.

Este indicador baseia-se indiretamente na coluna TotalAmount da tabela FactSales, através da medida base [Total Vendas], que agrega o valor monetário das transações no contexto de filtro atual.

A medida [Vendas Mês Anterior] utiliza a mesma base de dados, recorrendo à dimensão temporal DimData para aplicar um deslocamento cronológico que permite obter o valor correspondente ao mês anterior.

Desta forma, o cálculo do crescimento MoM resulta da comparação entre o valor atual das vendas e o respetivo valor do período imediatamente anterior, garantindo coerência temporal e consistência analítica.

2. Crescimento YoY (%) (Ano anterior):

```
Crescimento YoY % :=
VAR Atual = [Total Vendas]
VAR Anterior =
    CALCULATE (
        [Total Vendas],
        DATEADD ( DimData[Date], -1, YEAR )
    )
RETURN
DIVIDE ( Atual - Anterior, Anterior )
```

Figura 22- Crescimento YoY (%)

A métrica Crescimento Year-over-Year (YoY) calcula a variação percentual das vendas face ao mesmo período do ano anterior, permitindo analisar o crescimento real do negócio, mitigando o impacto da sazonalidade.

Este indicador baseia-se indiretamente na coluna TotalAmount da tabela FactSales, através da medida [Total Vendas], que agrega o valor monetário das transações no contexto de filtro atual.

O crescimento YoY resulta, assim, da comparação entre o valor atual das vendas e o valor registado no mesmo período do ano anterior, assegurando consistência temporal e coerência analítica.

3. Aceleração de Vendas (Velocidade):

```
Velocidade de movimento de preço :=
VAR CrescAtual = [Crescimento MoM %]
VAR CrescAnterior =
    CALCULATE ( [Crescimento MoM %], DATEADD ( DimData[Date], -1, MONTH ) )
RETURN
CrescAtual - CrescAnterior
```

Figura 23- Aceleração de Vendas (Velocidade)

Esta métrica avalia a variação da taxa de crescimento das vendas ao longo do tempo. Baseia-se em:

- variações sucessivas do TotalAmount (*FactSales*),
- organizadas cronologicamente através da dimensão DimData.

A aceleração positiva indica crescimento sustentado; valores negativos indicam desaceleração.

9.3. Análise de Comportamento do Cliente

Indicadores desenhados para monitorizar a fidelização e os padrões de consumo da base de clientes.

1. Taxa de Repetição:

```
Taxa de Repetição := DIVIDE ( [Clientes Repetidos], [Nr Clientes] )
```

Figura 24- Taxa de Repetição

Esta métrica avalia a variação da taxa de crescimento das vendas ao longo do tempo. Baseia-se em:

- variações sucessivas do TotalAmount (*FactSales*),
- organizadas cronologicamente através da dimensão DimData.

A aceleração positiva indica crescimento sustentado; valores negativos indicam desaceleração.

2. Clientes Ativos:

```
Clientes Ativos :=
CALCULATE (
    [Nr Clientes],
    FactSales[Total Amount] > 0
)
```

Figura 25- Clientes Ativos

Filtra apenas os clientes que geraram receita efetiva, excluindo registos de devoluções totais ou inatividade:

- Receita positiva: FactSales[TotalAmount]
- Identificação do cliente: FactSales[Customer ID]

Esta abordagem exclui clientes sem impacto financeiro relevante no período em análise.

3. Número de Clientes:

```
Nr Clientes =
DISTINCTCOUNT ( dimCustomer[CustomerID] )
```

Figura 26- Números de Clientes

A métrica Nr Clientes é calculada através da função DISTINCTCOUNT aplicada à coluna CustomerID da tabela de dimensão DimCustomer. Esta função percorre a lista de clientes registados na dimensão e contabiliza apenas os valores únicos, eliminando quaisquer duplicados.

4. Clientes Repetidos

```
Clientes Repetidos =
CALCULATE (
    [Nr Clientes],
    FILTER (
        VALUES ( dimCustomer[CustomerID]),
        CALCULATE ( [Nr Transações] ) > 1
    )
)
```

Figura 27- Clientes Repetidos

Esta medida quantifica a fidelização da base de clientes. Através de uma função de iteração (FILTER), a fórmula isola e contabiliza apenas os clientes que registaram mais do que uma transação no período analisado. Este indicador é crucial para distinguir compras isoladas de padrões de consumo recorrente e avaliar a eficácia das estratégias de retenção.

9.4. Análise Estatística Avançada

Conjunto de métricas complexas para deteção de padrões, riscos e anomalias nos dados.

1. Correlação Quantidade vs. Vendas:

```
Correlação Quantidade vs Vendas :=
VAR T = SUMMARIZE ( FactSales, DimData[Date], "Qtd", [Quantidade Total], "Vlr", [Total Vendas]
)
VAR AvgQtd = AVERAGEX ( T, [Qtd] )
VAR AvgVlr = AVERAGEX ( T, [Vlr] )
VAR Numerador = SUMX ( T, ( [Qtd] - AvgQtd ) * ( [Vlr] - AvgVlr ) )
VAR Denominador = SQRT ( SUMX ( T, POWER ( [Qtd] - AvgQtd, 2 ) ) * SUMX ( T, POWER ( [Vlr] -
AvgVlr, 2 ) ) )
RETURN
DIVIDE ( Numerador, Denominador )
```

Figura 28- Correlação Quantidade vs Vendas

A métrica Correlação Quantidade vs. Vendas calcula o coeficiente de correlação de Pearson, com o objetivo de avaliar a relação estatística entre o volume de unidades vendidas e o valor monetário das vendas.

O cálculo baseia-se indiretamente nas colunas Quantity e TotalAmount da tabela FactSales, através das medidas [Quantidade Total] e [Total Vendas], respetivamente.

O coeficiente resultante assume valores no intervalo , permitindo identificar se o aumento do volume de vendas se traduz proporcionalmente em crescimento da receita ou, pelo contrário, se existem indícios de ineficiência comercial, como vendas impulsionadas por descontos excessivos.

2. Z-Score Vendas (Deteção de Anomalias):

```
Z-Score Vendas = VAR MediaGlobal =
    CALCULATE(
        [Total Vendas],
        ALL(dimData),
        ALL(dimCustomer),
        ALL(dimGender),
        ALL(dimFaixa_Etaria),
        ALL('dimProduct Category')
    ) /
    CALCULATE(
        COUNTROWS(VALUES(dimData[Date])),
        ALL(dimData),
        ALL(dimCustomer),
        ALL(dimGender),
        ALL(dimFaixa_Etaria),
        ALL('dimProduct Category')
    )
VAR DesvioPadrao =
    STDEVX.S(
        CALCULATETABLE(
            ADDCOLUMNS(
                VALUES(dimData[Date]),
                "VendasDia", [Total Vendas]
            ),
            ALL(dimData),
            ALL(dimCustomer),
            ALL(dimGender),
            ALL(dimFaixa_Etaria),
            ALL('dimProduct Category')
        ),
        [VendasDia]
    )
VAR VendaAtual = [Total Vendas]
RETURN
    DIVIDE(VendaAtual - MediaGlobal, DesvioPadrao)
```

Figura 29- Z-Score Vendas

A métrica Z-Score de Vendas foi desenvolvida com o objetivo de identificar valores de vendas estatisticamente anómalos ao longo do tempo. O cálculo baseia-se na medida [Total Vendas], agregada ao nível diário através da dimensão temporal *DimData*.

A média global e o desvio padrão das vendas diárias são calculados removendo o contexto de filtro das principais dimensões, permitindo comparar cada valor diário com o comportamento global das vendas. Valores absolutos de Z-Score superiores a 2 são considerados potenciais outliers, podendo indicar picos de vendas ou comportamentos atípicos.

3. Elasticidade Preço-Quantidade:

```
Elasticidade Preço-Quantidade :=
VAR P0 = [Preço Médio Unitário]
VAR Q0 = [Quantidade Total]
VAR P1 = CALCULATE ( [Preço Médio Unitário], DATEADD ( DimData[Date], -1, MONTH ) )
VAR Q1 = CALCULATE ( [Quantidade Total], DATEADD ( DimData[Date], -1, MONTH ) )
VAR dP = DIVIDE ( P0 - P1, P1 )
VAR dQ = DIVIDE ( Q0 - Q1, Q1 )
RETURN
DIVIDE ( dQ, dP )
```

Figura 30- Elasticidade Preço-Quantidade

A métrica Elasticidade Preço–Quantidade foi desenvolvida com o objetivo de medir a sensibilidade da procura à variação do preço ao longo do tempo.

O cálculo baseia-se indiretamente nas colunas TotalAmount e Quantity da tabela FactSales, através das medidas [Preço Médio Unitário] e [Quantidade Total], respetivamente. O preço médio unitário é obtido como a razão entre o valor total das vendas e a quantidade vendida no período em análise.

Para o cálculo da elasticidade, são comparados os valores atuais de preço e quantidade com os respetivos valores do mês anterior, recorrendo à função DATEADD aplicada à dimensão temporal DimData.

O resultado representa a razão entre a variação percentual da quantidade e a variação percentual do preço, permitindo identificar comportamentos elásticos (|E| > 1) ou inelásticos (|E| < 1), bem como situações anómalas quando o sinal da elasticidade não corresponde ao esperado.

9.5. Segmentação e Concentração (Pareto)

1. % Vendas Top 10 Clientes:

```
% Vendas Top 10 Clientes :=
VAR TopClientes = TOPN ( 10, VALUES ( DimCustomer[Customer ID] ), [Total Vendas], DESC )
VAR VendasTop = CALCULATE ( [Total Vendas], TopClientes )
RETURN
DIVIDE ( VendasTop, CALCULATE ( [Total Vendas], ALL ( DimCustomer ) ) )
```

Figura 31- Vendas Top 10 Clientes

Esta métrica avalia a dependência do negócio face aos seus principais clientes:

- Identificação de clientes: FactSales [Customer ID]
- Receita: FactSales [TotalAmount]

A métrica é calculada e ordena os clientes por volume de vendas e agregando os 10 principais.

2. Índice Afinidade Categoria:

```
Índice Afinidade Categoria :=
DIVIDE (
    [Total Vendas],
    CALCULATE ( [Total Vendas], ALL ( DimFaixa_Etaria ) )
)
```

Figura 32- Índice Afinidade Categoria

Esta métrica compara o peso de uma categoria num determinado segmento face à média global:

- Categoria do produto: DimProduct_Category [Product Category]
- Receita associada: FactSales [TotalAmount]
- Segmentação demográfica: DimGender e DimFaixa_Etaria

Valores superiores a 1 indicam afinidade acima da média.

10. Dashboard e visualizações

A etapa final do projeto consistiu na criação de um ecossistema de visualização no Power BI, traduzindo o modelo de dados em indicadores de performance de negócio. O dashboard está organizado em quatro áreas analíticas: Vendas, Clientes, Produtos e Segmentos.

10.1. Escolha dos tipos de visualização

A escolha dos tipos de visualização no projeto de Bases de Dados e Data Warehouses reflete uma intenção clara de equilibrar a monitorização de indicadores imediatos com a análise profunda de tendências e distribuições.

Abaixo, descrevo a lógica por trás das escolhas gráficas observadas nas fontes:

• Cartões de Indicadores (KPI Cards): Foram utilizados no topo de todas as páginas para destacar métricas críticas como o Total de Vendas, Crescimento YoY e Ticket Médio. Esta escolha é ideal para uma leitura rápida, permitindo que o utilizador identifique imediatamente o estado geral do negócio sem distrações.

• Gráfico de Áreas e Gráfico de Linhas: Na análise de vendas e evolução de produtos, optou-se por gráficos de áreas e de linhas. O gráfico de áreas na aba "Vendas" enfatiza a magnitude do volume ao longo do tempo, enquanto o gráfico de linhas na aba "Produtos" é a escolha perfeita para comparar as trajetórias de múltiplas categorias (Eletrónica, Roupa, Beleza) simultaneamente, permitindo identificar picos e quedas sazonais de forma clara.

• Treemap (Mapa de Árvore): Este formato foi aplicado para cruzar "Mês vs Dia da Semana". A escolha é astuta pois utiliza o tamanho e a cor dos retângulos para representar a densidade de vendas, permitindo perceber num relance quais os períodos (meses e dias) mais lucrativos sem sobrecarregar a visualização com eixos complexos.

• Gráfico de Dispersão (Bubble Chart): Utilizado na análise de clientes para cruzar o Ticket Médio com o Total de Vendas. Este tipo de gráfico é o mais indicado para identificar padrões de comportamento, agrupamentos de clientes e *outliers* (clientes que fogem à norma), utilizando as cores para distinguir o género.

• Gráficos de Barras Horizontais: Escolhidos para a comparação de categorias e segmentos. A orientação horizontal facilita a leitura dos rótulos e permite uma comparação direta e intuitiva do desempenho entre categorias de produtos ou entre géneros (Feminino vs Masculino).

• Gráfico de Donut (ou Anel): Aplicado na segmentação por faixa etária. Este gráfico foca-se na composição do todo, sendo eficaz para mostrar a distribuição proporcional das vendas entre diferentes grupos de idade de forma estética e organizada.

10.2. Interpertação dos resultados

1. Análise de Vendas e Performance Global

O módulo de vendas centraliza os principais indicadores financeiros e estatísticos do projeto:

• KPIs Fundamentais: O volume total de vendas registado é de 456 mil, proveniente de 1.000 transações, resultando num ticket médio de 456,00.

• Métricas Estatísticas: O dashboard integra cálculos avançados, como a correlação de 0,71 entre Quantidade e Vendas, indicando uma relação positiva forte entre o volume de itens e o valor faturado. Inclui ainda o desvio padrão das vendas (1,22K) e 12 dias considerados outliers.

• Análise Temporal: Observa-se um crescimento homólogo (YoY) de 11,86%. A distribuição temporal revela picos de atividade nos meses de junho e novembro de 2023, permitindo identificar padrões de sazonalidade no modelo de dados.

2. Caracterização e Concentração de Clientes

A análise de clientes foca-se na distribuição de valor por utilizador:

• Fidelização e Volume: A base conta com 1.000 clientes ativos. A análise de concentração demonstra que os 10 principais clientes representam 21% da faturação total.

• Distribuição de Valor: Através de um gráfico de dispersão, o dashboard correlaciona o ticket médio com o total de vendas por cliente, permitindo identificar o posicionamento de cada consumidor e o peso do género na distribuição de valor. O valor de P90 para o ticket por transação fixa-se em 1,20K.

3. Desempenho por Categoria de Produto

O portfólio de produtos está dividido em três categorias principais: Beauty, Clothing e Electronics.

• Análise Comparativa: A categoria Electronics apresenta o desempenho mais elevado, com um total de 156.905 em vendas e o maior crescimento homólogo do portfólio (14,86%).

• Volume de Itens: No total, foram comercializadas 2.514 unidades, com as categorias Beauty e Clothing a apresentarem valores de crescimento e ticket médio muito aproximados entre si.

4. Segmentação Demográfica e de Género

O último eixo do dashboard cruza os dados de vendas com o perfil demográfico dos consumidores:

• Preferências por Género: Identifica-se que o segmento feminino gera maior volume na categoria Clothing (81K), enquanto o segmento masculino lidera na categoria Electronics (80K).

• Estrutura Etária: O modelo segmenta o mercado em cinco faixas etárias (desde menores de 25 até à faixa 55-64 anos), permitindo visualizar a penetração de cada categoria de produto em diferentes gerações através de uma análise concêntrica.

11. Conclusão

Ao longo do projeto foi possível percorrer todas as etapas fundamentais de um processo analítico completo, desde a compreensão do negócio e normalização dos dados, até à construção de um modelo dimensional, desenvolvimento de métricas avançadas em DAX e criação de dashboards interativos no Power BI.

A normalização dos dados até à Terceira Forma Normal permitiu eliminar redundâncias e garantir a integridade lógica do modelo relacional, assegurando uma base sólida para a posterior construção do Data Warehouse. O modelo dimensional em estrela revelou-se adequado às necessidades analíticas do projeto, o que levou consultas eficientes, correta propagação de filtros e suporte a análises temporais e segmentadas. A criação de uma dimensão temporal dedicada mostrou-se particularmente relevante para a implementação de métricas de inteligência temporal.

Ao nível analítico, o conjunto de métricas desenvolvidas permitiu responder de forma clara às questões de negócio que definimos inicialmente, fornecendo insights relevantes sobre o desempenho de vendas, comportamento dos clientes, sazonalidade, concentração de receita e preferências por categoria e segmento demográfico. A inclusão de métricas estatísticas avançadas, como correlação, elasticidade e deteção de anomalias, acrescentou

profundidade à análise, indo além dos indicadores tradicionais e aproximando o trabalho de um contexto real de apoio à decisão.

Traduzimos, assim, uma aplicação consistente dos princípios de Bases de Dados e Data Warehouse a um contexto de análise de vendas, assegurando alinhamento entre dados, modelo e indicadores. As decisões tomadas ao nível da modelação e da análise refletem-se diretamente nos resultados obtidos, o que permite uma leitura objetiva do desempenho do negócio suportada por dados estruturados.

12. Referências

AndreasMeier ,Michael Kaufmann, SQL & Nosql Databases, Editoras: Springer Fachmedien Wiesbaden, julho 2019.

Azevedo, A., Abreu, A., Carvalho, V., Desenho e Implementação de Bases de Dados com Microsoft Access XP, Centro Atlântico, 2002.

Azevedo, A., et al. Diapositivos. SIG –LCA .

C. P. Caldeira, Data Warehousing -Conceitose Modelos, EdiçõesSilabo, 2009.

Data Mining, Concepts and Techniques , Micheline Kamberand Jiawei Han, 2000, Morgan Kaufmann Publishers, ISBN 1-55860-489-8

Developing, and Deploying Data Warehouses. , Ralph Kimball, Laura Reeves, MargyRoss, Warren Thornthwaite, 1998, Wiley

E. Turban, R. Sharda, J. Aronson, D. King, Business Intelligence: a managerial approach, Prentice Hall, 2007.

Gonçalves, C. T. Diapositivos. BD –LCTDI .

Kimball, Ralph 070; The Data Warehouse lifecycle toolkit.

M. F. Santos e C. S. Azevedo, Data Mining -Descobertade ConhecimentoemBases de Dados, EditoraFCA, 2009.

M. Y. Santos e I. Ramos, Business Intelligence -Tecnologiasda InformaçãonaGestãode Conhecimento-2.a EdiçãoAtualizadae Aumentada, EditoraFCA, 2008.

Pereira, J. L., Tecnologia de Bases de Dados, FCA, 1998.

Rodrigues, L. S., et al., Diapositivos Informática II –LCA .

W. H. Inmon, Building the Data Warehouse (4th Ed edition), Hungry Minds Inc, 2005

W3C - https://www.w3schools.com/sql/